

Examen final - Procesamiento de Señales Biomédicas

**Diagnóstico diferencial automático de
miopatías y neuropatías mediante el
procesamiento digital de señales de EMG**

Procesamiento de Señales e Imágenes Biomédicas

1er Cuatrimestre de 2026

Grupo 10

Fecha de entrega: /07/2026

Autores:

Caroccia, Franco (Legajo: 64445)

Kestelboim, Andres (Legajo: 64430)

Suarez, Ivan Nicolas (Legajo: 63770)

Índice

Índice	2
1. Introducción	3
1.1. Marco teórico	3
1.2. Estado del arte	3
2. Problemática	3
2.1. Base de datos	4
3. Objetivos y diseño	4
3.1. Objetivo general	4
3.2. Objetivos puntuales	4
3.3. Diseño del algoritmo	5
3.4. Objetivos de mínima y de máxima	5
4. Desarrollo	5
4.1. Técnicas de acondicionamiento de la señal	5
4.2. Algoritmos de procesamiento para la extracción de información relevante	6
4.3. Técnica novedosa de procesamiento: Transformada Wavelet	6
4.4. Modelos de clasificación de Aprendizaje Automático y Redes Neuronales	7
5. Resultados	8
5.1. Preprocesamiento	8
5.2. Segmentación de MUAPs	8
5.3. Caracterización ampliada	8
5.4. Análisis de componentes principales (PCA)	8
5.5. Resultados de clasificación	8
Random Forest	9
Red Neuronal (MLP)	9
Comparación entre modelos	9
6. Conclusión	9
Bibliografía	11
Anexo	12
A.1. Hiperparámetros de los modelos	12
A.2. Estructura del repositorio entregado	12

1. Introducción

1.1. Marco teórico

El sistema neuromuscular puede verse afectado por diversas patologías que comprometen la capacidad motora del paciente, clasificándose principalmente en trastornos musculares intrínsecos (**miopatías**) o afecciones de las neuronas motoras y nervios periféricos (**neuropatías**). La Electromiografía (EMG) intramuscular, realizada mediante electrodos de aguja concéntrica, constituye la herramienta clínica estándar para evaluar la integridad fisiológica de las Unidades Motoras (UM) [7].

Desde la perspectiva del procesamiento de señales, el registro de EMG representa la suma espacio-temporal de los Potenciales de Acción de la Unidad Motora (MUAPs, por sus siglas en inglés). En condiciones patológicas, la morfología de estos MUAPs sufre alteraciones predecibles, cuantificadas originalmente por Buchthal et al. [5] y estandarizadas internacionalmente por la International Federation of Clinical Neurophysiology [6]:

- Miopatías: ocasionan la pérdida aleatoria de fibras musculares dentro de la UM. El nervio dispara correctamente, pero la respuesta del tejido es débil y asincrónica, manifestándose en MUAPs de corta duración, baja amplitud y una morfología altamente polifásica debido a la dispersión de la velocidad de conducción [7].
- Neuropatías: provocan la muerte de neuronas motoras. Las neuronas sobrevivientes reinervan a las fibras huérfanas mediante brotes colaterales (sprouting axonal), incrementando el tamaño de la UM. Esto produce MUAPs con amplitudes elevadas y duraciones prolongadas [7].

1.2. Estado del arte

El análisis cuantitativo de la electromiografía (qEMG) evolucionó de manera sustancial desde las primeras mediciones manuales y evaluaciones visuales hasta convertirse en un campo fuertemente impulsado por el procesamiento digital de señales. Los métodos automáticos tempranos, como el clásico análisis de giros y amplitudes de Willison [3] o los primeros algoritmos de aislamiento e interferencia de potenciales propuestos por Stålberg et al. [4], sentaron las bases para la parametrización clínica de la unidad motora.

En la actualidad, el estado del arte en neurofisiología clínica se orienta a mitigar la subjetividad del operador mediante flujos de procesamiento robustos y estandarizados internacionalmente [6]. Los enfoques más modernos combinan filtrado adaptativo con segmentación dinámica basada en el modelado estocástico del ruido de fondo, en línea con técnicas de detección de picos desarrolladas originalmente para el análisis de spikes neuronales, como el método de umbralización adaptativa con transformada Wavelet propuesto por Quiroga et al. [2]. Estas herramientas permiten la extracción automatizada de características morfológicas complejas y consolidan a los algoritmos de aprendizaje automático como instrumentos objetivos para el diagnóstico diferencial temprano.

En paralelo, la incorporación de técnicas de tiempo-frecuencia (Transformada Wavelet) y de Aprendizaje Automático/Redes Neuronales para la clasificación automática de patologías neuromusculares a partir de parámetros de EMG viene ganando terreno como complemento de la evaluación clínica, dado que permite capturar patrones morfológicos sutiles que la inspección visual del especialista podría pasar por alto, en particular cuando la variabilidad inter-sujeto es alta.

2. Problemática

El diagnóstico diferencial entre miopatías y neuropatías mediante EMG intramuscular depende hoy, en gran medida, de la inspección visual y la experiencia del neurofisiólogo que evalúa la morfología de

los MUAPs en tiempo real durante el estudio. Este procedimiento es inherentemente subjetivo, no es completamente reproducible entre observadores, y su curva de aprendizaje es larga. Automatizar la extracción de parámetros cuantitativos y su posterior clasificación mediante algoritmos de Aprendizaje Automático (AA) o Redes Neuronales (RN) permite reducir esa subjetividad, estandarizar el análisis entre centros y sentar las bases para herramientas de apoyo diagnóstico (CAD, computer-aided diagnosis).

La propuesta de trabajo consiste en desarrollar un pipeline completo en Python que, partiendo de la señal cruda de EMG intramuscular, realice: (i) acondicionamiento de la señal, (ii) segmentación y caracterización cuantitativa de los MUAPs individuales, (iii) extracción de una técnica novedosa de procesamiento (transformada Wavelet) y (iv) clasificación automática en sano / miopatía / neuropatía mediante dos modelos de AA y RN distintos, cuyo desempeño se compara cuantitativamente.

2.1. Base de datos

Se utilizan las señales de electromiografía intramuscular publicadas en el dataset “*Electromyographic data recordings during isometric contractions of the biceps brachii and deltoid collected from patients and healthy subjects*” de Mendeley Data [1], disponible en <https://doi.org/10.17632/543xpjycj9.1>.

Las señales fueron adquiridas mediante electrodo de aguja concéntrica sobre el músculo deltoides y el bíceps braquial durante contracción isométrica, en tres grupos: 50 sujetos control sin antecedentes neuromusculares (23 mujeres, 27 hombres, 17-56 años), 98 sujetos con miopatía (55 mujeres, 43 hombres, 4-78 años) y 93 sujetos con neuropatía (53 mujeres, 40 hombres, 2-81 años). Según el conteo de archivos realizado sobre el propio dataset, se dispone de 400 señales (100 sanas, 50 miopáticas y 50 neuropáticas por músculo), con un ancho de banda de 16 a 5000 Hz muestreadas a 32768 Hz [1].

El dataset tiene una limitación metodológica que conviene aclarar desde el inicio: las etiquetas disponibles corresponden al diagnóstico del paciente (sano/miopatía/neuropatía) y no a cada MUAP individual dentro de su registro. En este trabajo se asume que todos los MUAPs segmentados de una señal patológica heredan la etiqueta de esa señal, lo cual introduce una fuente de ruido en el etiquetado debido a que no todos los MUAPs de un paciente enfermo son necesariamente atípicos, algo que se retoma en la sección de Conclusión.

3. Objetivos y diseño

3.1. Objetivo general

Desarrollar un algoritmo en Python que permita procesar señales de EMG intramuscular provenientes de una base de datos pública para caracterizar y clasificar automáticamente registros de sujetos sanos, con miopatías y con neuropatías, a partir de parámetros morfológicos, espectrales y de tiempo-frecuencia de los MUAPs.

3.2. Objetivos puntuales

1. Diseñar e implementar una etapa de acondicionamiento de la señal de EMG intramuscular que remueva ruido de línea y ruido de banda ancha sin distorsionar la morfología de los MUAPs.
2. Segmentar automáticamente los MUAPs individuales mediante un algoritmo de detección por umbral adaptativo basado en la desviación estándar del ruido de fondo.
3. Extraer, para cada MUAP, un conjunto ampliado de características temporales (duración, amplitud, fases, giros, forma de onda), espectrales (frecuencias media y mediana, energía por banda) y de tiempo-frecuencia mediante Transformada Wavelet.

4. Consolidar las características de ambos músculos (deltoides y bíceps braquial) en un único dataset de entrenamiento.
5. Entrenar y comparar dos modelos de clasificación de naturaleza distinta, uno de Aprendizaje Automático clásico (Random Forest) y uno de Red Neuronal (Perceptrón Multicapa), capaces de discriminar entre sujetos sanos, miopáticos y neuropáticos.
6. Evaluar cuantitativamente el desempeño de ambos modelos y determinar qué características resultan más relevantes para la discriminación entre clases.

3.3. Diseño del algoritmo

El algoritmo ideal se estructura como un pipeline secuencial de cinco etapas: (1) acondicionamiento de la señal cruda, (2) segmentación adaptativa de MUAPs, (3) extracción de características multidominio, (4) reducción de dimensionalidad/visualización (PCA) y (5) clasificación mediante dos modelos de AA y RN entrenados sobre el dataset consolidado.

Comparación con antecedentes: el enfoque de segmentación adoptado se inspira en técnicas de detección de picos con umbral adaptativo desarrolladas por Quiroga et al. [2] para spike sorting, adaptadas aquí al contexto de MUAPs de EMG intramuscular. El conteo de fases y giros sigue el criterio clásico de Willison [3], mientras que los rangos de referencia para duración y amplitud en sujetos sanos se basan en Buchthal et al. [5] y en los estándares actuales de cuantificación de EMG [6]. A diferencia de estos antecedentes, que se limitan a la caracterización estadística descriptiva, este trabajo incorpora la clasificación automática mediante modelos de AA y RN sobre un vector de características ampliado.

3.4. Objetivos de mínima y de máxima

- Objetivo de mínima: contar con un pipeline funcional de extremo a extremo (acondicionamiento, segmentación, extracción de características, clasificación) que supere el desempeño de un clasificador trivial: tanto el azar uniforme (33% para 3 clases) como la predicción constante de la clase mayoritaria, esta última más exigente dado el desbalance entre grupos (sano/miopatía/neuropatía).
- Objetivo de máximo: lograr una discriminación robusta y estadísticamente significativa entre las tres condiciones, validando los resultados con una separación por paciente (no por MUAP individual) entre entrenamiento y prueba, para evitar fuga de información (data leakage), y complementar el análisis con pruebas estadísticas de diferencia entre grupos.

4. Desarrollo

4.1. Técnicas de acondicionamiento de la señal

Las señales crudas presentan ruido de alta potencia y un componente evidente de ruido de línea en 50 Hz, lo que requiere una etapa de acondicionamiento previa a la extracción de características. Se aplica en primer lugar un filtro pasa banda IIR Butterworth de cuarto orden (20-1000 Hz) para acotar el ancho de banda útil del MUAP, seguido de un filtro notch en 50 Hz para eliminar el ruido de línea. Los parámetros morfológicos que se calculan más adelante son sensibles al ruido residual, así que se agrega un filtro óptimo de Wiener que reduce de forma adaptativa el ruido blanco gaussiano de la etapa de amplificación analógica, mejorando la relación señal-ruido sin suavizar los picos críticos de los potenciales.

4.2. Algoritmos de procesamiento para la extracción de información relevante

Para la segmentación de los MUAPs se diseñó un algoritmo de umbralización adaptativa basado en la desviación estándar del ruido de fondo en reposo. Se identifican picos cuando la señal supera un umbral igual a 4 veces la desviación estándar del ruido (calculado individualmente por señal), y cada MUAP se recorta en una ventana de 30 ms centrada en su pico principal.

Con cada realización aislada se calculan las cuatro características clásicas del análisis cuantitativo de EMG:

- Duración total: obtenida mediante una envoltura de energía (media móvil de 1.5 ms sobre el valor absoluto) con criterio de permanencia de 0.8 ms por debajo de un umbral adaptativo, para ubicar el inicio y fin real del potencial.
- Amplitud pico a pico: valor máximo menos valor mínimo dentro de la ventana útil delimitada por la duración.
- Número de fases: mediante un detector con histéresis que sólo cuenta una nueva fase si supera 1.5 veces la desviación estándar del ruido, evitando contar oscilaciones espurias.
- Número de giros: cambios de dirección de la pendiente validados con un umbral de histéresis de 2 veces la desviación estándar del ruido (piso mínimo de 30 μ V), para hacer al algoritmo inmune a micro-oscilaciones térmicas de línea de base.

A partir de la devolución recibida en la instancia de TP, y siguiendo la recomendación explícita de incorporar más métricas y características espectrales, se amplió el conjunto de features con:

- Features de forma de onda: área bajo la curva rectificadas (AUC), relación amplitud/duración, asimetría (skewness) y curtosis, que capturan aspectos de la morfología no reflejados en las 4 métricas clásicas.
- Features espectrales: frecuencia media y frecuencia mediana del espectro (vía FFT) de cada MUAP, y energía relativa en tres bandas (baja: 0-200 Hz, media: 200-500 Hz, alta: >500 Hz).

También se siguió la recomendación de aprovechar ambas señales por sujeto: el dataset final combina las características extraídas del músculo deltoides y del bíceps braquial en un único conjunto de entrenamiento, en lugar de analizarlos por separado como en la instancia previa.

4.3. Técnica novedosa de procesamiento: Transformada Wavelet

Como técnica de procesamiento avanzado no vista en el desarrollo estándar de la materia, se incorporó la **Transformada Wavelet Discreta (DWT)** para el análisis tiempo-frecuencia de cada MUAP. A diferencia de la Transformada de Fourier, que sólo brinda resolución en frecuencia, la Wavelet permite localizar simultáneamente en qué escala temporal y en qué banda de frecuencia se concentra la energía del potencial [8], lo cual es particularmente adecuado para señales transitorias y no estacionarias como los MUAPs. Un enfoque con precedente directo en el análisis de potenciales de acción mediante Wavelets propuesto por Quiroga et al. [2] para la detección y clasificación de spikes neuronales.

Cada MUAP se descompone mediante DWT con la wavelet madre Daubechies de orden 4 (db4) hasta el cuarto nivel de detalle, calculando la energía relativa de cada nivel (aproximación y 4 niveles de detalle) respecto a la energía total, junto con la entropía de Shannon de esa distribución. Esta entropía resume en un único número qué tan concentrada o dispersa está la energía del MUAP entre escalas: la hipótesis de trabajo es que los MUAPs polifásicos y desincronizados de miopatías y neuropatías muestren una energía más dispersa (mayor entropía) que los MUAPs sanos, más compactos en el dominio tiempo-frecuencia.

4.4. Modelos de clasificación de Aprendizaje Automático y Redes Neuronales

Con el vector de características consolidado (temporales, de forma, espectrales y de Wavelet) para ambos músculos, se estandarizaron las variables (media 0, desvío 1) y se aplicó un Análisis de Componentes Principales (PCA) con fines de visualización, para evaluar cualitativamente la separabilidad de las tres clases en un espacio de 2 dimensiones antes de entrenar los clasificadores.

Se entrenaron y compararon dos modelos de naturaleza distinta, ambos sobre una partición 80/20 de entrenamiento y prueba, estratificada por clase:

- Random Forest (Aprendizaje Automático clásico): ensamble de 300 árboles de decisión con balanceo de clases, elegido por su robustez frente a features en distintas escalas y por permitir interpretar la importancia relativa de cada característica en la clasificación [9].
- Red Neuronal (Perceptrón Multicapa, MLP): red densa con dos capas ocultas (64 y 32 neuronas, activación ReLU), entrenada mediante retropropagación del error con el optimizador Adam [10], sobre el mismo conjunto de features estandarizadas.

Ambos modelos se implementaron con la librería scikit-learn [11] y se evaluaron con las mismas métricas: accuracy, F1-score macro (que pondera igual a las tres clases, relevante dado el desbalance entre grupos) y matriz de confusión.

5. Resultados

5.1. Preprocesamiento

Se verificó el efecto del acondicionamiento sobre señales de ejemplo de cada grupo, comparando dominio temporal y espectral antes y después del filtrado. Se logró acotar la banda de frecuencia a 20-1000 Hz y anular el pico de interferencia de línea en 50 Hz, sin distorsionar visualmente la morfología de los MUAPs presentes en la señal.

5.2. Segmentación de MUAPs

El algoritmo de umbralización adaptativa permitió aislar automáticamente los MUAPs de cada señal, ajustando el umbral de detección a la amplitud propia de cada registro. La superposición de las realizaciones aisladas para señales miopáticas y neuropáticas evidenció, de forma cualitativa, los patrones esperados: potenciales de baja amplitud y alta variabilidad morfológica en miopatía, y potenciales de amplitud marcadamente elevada en neuropatía.

5.3. Caracterización ampliada

La Tabla 5.3.1 resume las características extraídas para el dataset consolidado (ambos músculos). Con el objetivo de robustecer el diagnóstico diferencial y alimentar modelos de clasificación supervisada, se amplió el vector de características de cada MUAP. Además de los parámetros morfológicos clásicos (amplitud, duración, fases y giros), se incorporaron métricas de distribución estadística (Skewness y Kurtosis), medidas energéticas (AUC, Ratio Amplitud/Duración) y parámetros en el dominio de la frecuencia (Frecuencia media y mediana, energía por bandas y Entropía Wavelet).

Característica	Sano (Media $\pm$ DE)	Miopatía (Media $\pm$ DE)	Neuropatía (Media $\pm$ DE)
Amplitud (μ V)	1164.795 $\pm$ 724.491	1564.366 $\pm$ 1069.779	3698.624 $\pm$ 2011.411
Duración (ms)	12.151 $\pm$ 7.081	12.812 $\pm$ 8.126	11.998 $\pm$ 6.897
Fases	4.145 $\pm$ 2.192	4.569 $\pm$ 2.946	3.632 $\pm$ 1.863
Giros	3.693 $\pm$ 2.540	4.265 $\pm$ 3.564	3.231 $\pm$ 2.109
AUC	2.870 $\pm$ 2.581	4.106 $\pm$ 3.942	9.119 $\pm$ 7.463
Ratio Amp/Dur	115.306 $\pm$ 75.181	133.086 $\pm$ 87.369	364.398 $\pm$ 214.665
Skewness	-0.495 $\pm$ 0.967	-0.427 $\pm$ 1.002	-0.137 $\pm$ 1.199
Kurtosis	0.703 $\pm$ 1.621	0.915 $\pm$ 1.967	0.876 $\pm$ 1.897
Frec. media (Hz)	220.062 $\pm$ 73.847	219.169 $\pm$ 96.706	196.498 $\pm$ 86.390
Frec. mediana (Hz)	181.214 $\pm$ 94.276	180.533 $\pm$ 106.825	158.116 $\pm$ 100.065
Energía banda baja	0.543 $\pm$ 0.243	0.506 $\pm$ 0.266	0.602 $\pm$ 0.251
Energía banda media	0.387 $\pm$ 0.220	0.355 $\pm$ 0.225	0.340 $\pm$ 0.225
Energía banda alta	0.070 $\pm$ 0.072	0.086 $\pm$ 0.094	0.058 $\pm$ 0.072

Entropía Wavelet	0.045 ± 0.044	0.055 ± 0.058	0.038 ± 0.042
------------------	-------------------	-------------------	-------------------

Tabla 5.3.1. Características extraídas por condición (deltoides + bíceps combinados).

Para la condición neuropática se destacan predominantemente las métricas de energía y tamaño de potencial. El área bajo la curva y la relación Amplitud/Duración triplican los valores vistos en sujetos sanos e ilustran claramente la hipertrofia de la unidad motora por la reinervación. Por otro lado, en el caso de la miopatía, su naturaleza desorganizada y fragmentada es capturada principalmente por los descriptores espectrales y de complejidad. Este tipo de señales registran los mayores niveles de energía de banda alta y de entropía Wavelet, lo cual refleja la alta frecuencia de micro oscilaciones producto de la conducción desincronizada de las fibras musculares remanentes.

5.4. Análisis de componentes principales (PCA)

A pesar de estas diferencias estadísticas en los promedios, la variabilidad individual de los MUAPs es considerable. Para evaluar la separabilidad global de los datos, se aplicó un Análisis de Componentes Principales (PCA), reduciendo la dimensionalidad del conjunto de características a dos componentes principales.

Como se observa en el mapa de dispersión de la Figura 5.4.1, existe un solapamiento masivo entre las clases en el centro del espacio latente. Aunque se perciben ligeras tendencias de elongación, la neuropatía hacia el extremo positivo del eje PC2 y la miopatía hacia los valores altos de PC1, la alta densidad de superposición demuestra que no existe una separabilidad lineal clara entre los sujetos sanos, miopáticos y neuropáticos. Esta complejidad geométrica y la superposición de las fronteras de decisión justifican la implementación de algoritmos de clasificación no lineales y de ensamble, tales como Random Forest y Perceptrón Multicapa (MLP), capaces de modelar relaciones multidimensionales complejas.




Figura 5.4.1: Dispersión PCA de cada clase

5.5. Resultados de clasificación

Random Forest




Figura 5.5.1: Matriz de confusión para el modelo de Random Forest




Figura 5.5.2: Importancia relativa de cada característica considerada

Condición	Precisión	Sensibilidad	f1-score	Support
Sano	0.79	0.91	0.84	1379
Miopatía	0.74	0.46	0.57	631
Neuropatía	0.89	0.94	0.92	661
Promedio	0.81	0.77	0.78	
Promedio ponderado	0.80	0.81	0.80	

Tabla 5.5.1: Métrica de rendimiento obtenidas para el modelo de Random Forest

Como se observa en la Figura 5.5.2, la arquitectura basada en árboles de decisión priorizó fuertemente las métricas energéticas y de magnitud por sobre las puramente temporales y frecuenciales. Las tres características con mayor peso predictivo fueron la relación Amplitud/Duración, la amplitud pico a pico y el área bajo la curva ya que estas concentran hasta un 46% de la importancia total del modelo. El aporte morfológico representa el segundo escalón de importancia con el número de fases y giros. Finalmente, las variables espectrales como las bandas de frecuencia o la entropía wavelet tienen aportes menores, actuando como descriptores complementarios que ayudan a refinar las fronteras de decisión finas.

A partir de la matriz de confusión de la Figura 5.5.1 y considerando el soporte de para cada clase, se observan diferencias claras en la capacidad de discriminación del modelo.

La clasificación de MUAPs neuropáticos presenta el desempeño más alto del sistema, alcanzando una sensibilidad del 93.6% y una precisión del 89.5%. El modelo distingue de manera casi perfecta la neuropatía de la miopatía, con solo 13 confusiones.

Para los sujetos sanos se identificaron correctamente 1248 registros, logrando una sensibilidad del 90.5%. Es decir que el modelo demuestra una sólida capacidad para reconocer la actividad bioeléctrica basal normal.

Finalmente, la miopatía resultó ser la clase de mayor dificultad para diagnosticar, con una sensibilidad de tan solo 46.3%. La principal fuente de error radica en la clasificación de 310 potenciales miopáticos como sanos. Desde el punto de vista fisiopatológico, esto podría deberse a que las miopatías generan potenciales atenuados de baja amplitud que, en señales con contracción leve o bajo nivel de ruido, son morfológicamente difíciles de diferenciar de los MUAPs normales de menor voltaje.

Red Neuronal (MLP)




Tabla 5.5.3: Métrica de rendimiento obtenidas para el modelo MLP

Condición	Precisión	Recall	f1-score	Support
Sano	0.83	0.83	0.83	1379
Miopatía	0.63	0.63	0.63	631
Neuropatía	0.93	0.94	0.93	661
Promedio	0.80	0.80	0.80	
Promedio ponderado	0.81	0.81	0.81	

Tabla 5.5.2: Métrica de rendimiento obtenidas para el modelo MLP

El modelo basado en una Red Neuronal del tipo Perceptrón Multicapa (MLP) alcanzó una precisión promedio ponderada de 0.81 y un F1-score macro de 0.80 (Tabla 5.5.2), demostrando una sólida capacidad para modelar las fronteras de decisión no lineales en el espacio de características.

Nuevamente, analizando la matriz de confusión plasmada en la figura 5.5.3, se puede evaluar la distribución de aciertos y errores obtenida. La clasificación de señales neuropáticas se mantiene como el mayor caso de éxito registrando una sensibilidad del 93.7%, una precisión del 93.0% y un F1-score de 0.93. Las firmas bioeléctricas de gran magnitud y energía de los macro-potenciales permiten que la red neuronal aisle esta condición con escasa confusión hacia las otras clases, solo 20 falsos miopáticos y 22 falsos sanos.

En el caso de las señales de músculos sanos, se alcanzó una sensibilidad de 82.9% y un F1-score de 0.83. El modelo mantiene una tasa de acierto elevada sobre el grupo de control normal.

Esta vez, la clasificación de potenciales miopáticos muestra una mejora respecto a los árboles de decisión, alcanzando una sensibilidad (Recall) del 62.6% y un F1-score de 0.63. Si bien persiste cierta confusión hacia la clase sana, la red logró rescatar un 16.3% más de potenciales miopáticos reales que el modelo de Random Forest.

Comparación entre modelos

Modelo	Precisión	F1-macro
Random Forest	0.80	0.78
MLP	0.81	0.80

Tabla 5.5.3: Tabla comparativa del desempeño final de cada modelo

Comparando los resultados finales para cada modelo, se puede afirmar que el El Perceptrón Multicapa supera globalmente al Random Forest, incrementando el F1-macro de 0.78 a 0.80. Considerando que la métrica F1-macro evalúa el desempeño otorgando el mismo peso a cada clase, sin importar el desbalance de soporte, este incremento confirma que el MLP ofrece un diagnóstico global más equilibrado.

Aunque el aumento de sensibilidad del MLP para detectar patrones miopáticos conllevó una ligera pérdida de especificidad sobre la clase sana, incrementando los falsos positivos miopáticos en sujetos sanos (208 en MLP vs 87 en Random Forest), desde una perspectiva de screening médico, el comportamiento del MLP resulta clínicamente preferible. En el diagnóstico de patologías neuromusculares, resulta considerablemente más crítico minimizar los falsos negativos que asumir un leve incremento en los falsos positivos, los cuales son posteriormente filtrados mediante el juicio del especialista y estudios complementarios.

6. Conclusión

El presente trabajo extendió el pipeline desarrollado durante la cursada para el procesamiento de señales de EMG intramuscular, incorporando un conjunto ampliado de características (temporales, espectrales y de tiempo-frecuencia vía Transformada Wavelet), la combinación de ambas señales musculares por sujeto, y dos modelos de clasificación de naturaleza distinta (Random Forest y Red Neuronal) entrenados para discriminar entre sujetos sanos, miopáticos y neuropáticos.

Se logró consolidar un pipeline automatizado de extremo a extremo totalmente operativo (acondicionamiento, segmentación, extracción de características, clasificación). El sistema superó tanto el umbral del azar uniforme (33.3%) como la predicción por clase mayoritaria. La inclusión de la Transformada Wavelet (DWT db4) y las métricas espectrales permitió elevar la capacidad predictiva global, alcanzando una precisión ponderada de 0.81 y un F1-score macro de 0.80 mediante el modelo MLP.

Se obtuvo una discriminación robusta y fisiológicamente coherente entre las tres condiciones clínicas, destacando la clasificación de neuropatías con un F1-score de 0.93 y logrando rescatar los patrones complejos de miopatía mediante fronteras no lineales (sensibilidad del 62.6% en MLP frente al 46.3% de Random Forest). Sin embargo, la validación se mantuvo mediante una partición a nivel de MUAP

individual y no por paciente, dejando pendiente el blindaje estricto contra la fuga de información (*data leakage*).

Limitaciones: es necesario remarcar que el etiquetado utilizado para entrenar los modelos es a nivel de paciente y no de MUAP individual, por lo que no puede garantizarse que cada MUAP segmentado sea representativo puro de su condición. La evaluación actual, además, particiona entrenamiento/prueba a nivel de MUAP; una validación más rigurosa debería particionar por paciente/señal completa, para evitar que el modelo aprenda patrones idiosincráticos de un sujeto presente tanto en entrenamiento como en prueba (*data leakage*). Por último, como ya se había observado en la instancia de TP, la alta dispersión (desvío estándar) de varias métricas extraídas limita la contundencia estadística de las diferencias entre grupos, algo que un análisis con pruebas estadísticas formales (p. ej. ANOVA o test no paramétricos entre grupos) permitiría cuantificar con mayor rigor.

Trabajo a futuro: como líneas de continuación se proponen (i) repetir el entrenamiento con una partición por paciente para obtener una estimación de desempeño más realista, (ii) incorporar pruebas estadísticas formales de diferencia entre grupos para cada característica extraída, (iii) explorar arquitecturas de Red Neuronal Convolutiva 1D directamente sobre la forma de onda cruda del MUAP (sin pasar por extracción manual de features), y (iv) buscar una base de datos con etiquetado a nivel de MUAP individual que permita validar de forma más estricta el algoritmo desarrollado.

Bibliografia

- [1] Messekher, A. (2023). Electromyographic data recordings during isometric contractions of the biceps brachii and deltoid collected from patients and healthy subjects [Dataset]. Data Archiving and Networked Services (DANS). <https://doi.org/10.17632/543xpjycj9.1>
- [2] Quiroga, R. Q., Nadasdy, Z., & Ben-Shaul, Y. (2004). Unsupervised Spike Detection and Sorting with Wavelets and Superparamagnetic Clustering. *Neural Computation*, 16(8), 1661-1687. <https://doi.org/10.1162/089976604774201631>
- [3] Willison, R. G. (1964). Analysis of electrical activity in healthy and dystrophic muscle in man. *Journal of Neurology, Neurosurgery, and Psychiatry*, 27(5), 386-394. <https://doi.org/10.1136/jnnp.27.5.386>
- [4] Stålberg, E., Chu, J., Bril, V., Nandedkar, S., Stålberg, S., & Ericsson, M. (1983). Automatic analysis of the EMG interference pattern. *Electroencephalography and Clinical Neurophysiology*, 56(6), 672-681. [https://doi.org/10.1016/0013-4694\(83\)90035-4](https://doi.org/10.1016/0013-4694(83)90035-4)
- [5] Buchthal, F., Guld, C., & Rosenfalck, P. (1954). Action potential parameters in normal human muscle and their dependence on physical variables. *Acta Physiologica Scandinavica*, 32(2-3), 200-218. <https://doi.org/10.1111/j.1748-1716.1954.tb01167.x>
- [6] Stålberg, E., van Dijk, H., Falck, B., Kimura, J., Neuwirth, C., Pitt, M., Podnar, S., Rubin, D. I., Rutkove, S., Sanders, D. B., Sonoo, M., Tankisi, H., & Zwarts, M. (2019). Standards for quantification of EMG and neurography. *Clinical Neurophysiology*, 130(9), 1688-1729. <https://doi.org/10.1016/j.clinph.2019.05.008>
- [7] Preston, D. C., & Shapiro, B. E. (2012). *Electromyography and Neuromuscular Disorders E-Book: Clinical-Electrophysiologic Correlations*. Elsevier Health Sciences.
- [8] Mallat, S. (1989). A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7), 674-693. <https://doi.org/10.1109/34.192463>
- [9] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- [10] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536. <https://doi.org/10.1038/323533a0>
- [11] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Anexo

A.1. Hiperparámetros de los modelos

Modelo	Hiperparámetro	Valor
Random Forest	n_estimators	300
Random Forest	class_weight	balanced
Random Forest	random_state	42
MLP	hidden_layer_sizes	(64, 32)
MLP	activation	ReLU
MLP	solver	Adam
MLP	alpha (L2)	1e-3
MLP	max_iter	1000
Wavelet	wavelet madre	db4
Wavelet	niveles de descomposición	4
PCA	n_components	2
Split	train/test	80% / 20% (estratificado)

A.2. Estructura del repositorio entregado

- psib2026q1_tps_grupo10_caroccia_kestelboim_suarez_FINAL.py / .ipynb: notebook con todo el pipeline (acondicionamiento, segmentación, extracción de features, PCA y ambos modelos de clasificación).
- PSIB2026Q1-FINAL-Caroccia Kestelboim Suarez.pdf: presente informe.
- Presentación (.pptx) utilizada para la defensa oral.