

Diagnóstico diferencial automático de miopatías y neuropatías mediante el procesamiento digital de señales de EMG

Suárez, Iván Nicolás (Legajo 63770)

Kestelboim, Andrés (Legajo 64430)

Caroccia, Franco (Legajo 64445)

Contenidos



Introducción y problemática

Marco teórico, estado del arte y motivación clínica



Base de datos

400 señales de EMG intramuscular, tres condiciones



Objetivos y diseño

Pipeline propuesto y metas de mínima y máxima



Desarrollo del pipeline

Acondicionamiento, segmentación, features y Wavelet



Resultados

PCA, Random Forest y Red Neuronal (MLP)



Conclusión

Comparación de modelos y trabajo a futuro

Patologías con propiedades eléctricas diferentes

La EMG intramuscular con electrodo de aguja concéntrica es el estándar clínico para evaluar la Unidad Motora (UM). Cada MUAP registrado es la suma espacio-temporal de los potenciales de acción de una UM, y su morfología se altera de forma predecible según la patología.



Miopatías


- Pérdida aleatoria de fibras musculares dentro de la UM.
- El nervio dispara correctamente, pero la respuesta del tejido es débil y asincrónica.
- MUAPs de corta duración, baja amplitud y morfología muy polifásica.



Neuropatías

- Muerte de neuronas motoras por la afección del nervio periférico.
- Las neuronas sobrevivientes reinervan fibras huérfanas por sprouting axonal.
- MUAPs de amplitud elevada y duración prolongada.

De la inspección visual al aprendizaje automático



En paralelo, las **técnicas de tiempo-frecuencia (Wavelet)** y de **Aprendizaje Automático / Redes Neuronales** ganan terreno para capturar patrones morfológicos sutiles que la inspección visual podría pasar por alto, sobre todo con alta variabilidad inter-sujeto.

Diagnóstico subjetivo y dependiente del operador



El diagnóstico diferencial entre miopatías y neuropatías depende, hoy, de la **inspección visual y la experiencia del neurofisiólogo** que evalúa los MUAPs en tiempo real.

- Es inherentemente subjetivo
- No es completamente reproducible entre observadores
- Su curva de aprendizaje es larga



Propuesta: un pipeline en Python que realiza acondicionamiento de la señal, segmentación y caracterización de MUAPs, extracción de una técnica novedosa (Wavelet) y clasificación automática sano / miopatía / neuropatía mediante dos modelos comparados cuantitativamente.

Mendeley Data: EMG de bíceps braquial y deltoides

Electrodo de aguja concéntrica, contracción isométrica - ancho de banda 16–5000 Hz, muestreo a 32768 Hz

50

sujetos control

23 mujeres - 27
hombres, 17–56 años

98

con miopatía

55 mujeres - 43
hombres, 4–78 años

93

con neuropatía

53 mujeres - 40
hombres, 2–81 años

400

señales totales

ambos músculos
combinados

Limitación metodológica: las etiquetas corresponden al diagnóstico del paciente, no a cada MUAP individual. Se asume que todos los MUAPs segmentados heredan la etiqueta de la señal, introduciendo ruido de etiquetado.

Objetivo general y objetivos puntuales

Desarrollar un algoritmo en Python que procese EMG intramuscular para caracterizar y clasificar automáticamente sujetos sanos, con miopatías y con neuropatías, a partir de parámetros morfológicos, espectrales y de tiempo-frecuencia.

1

Acondicionar la señal sin distorsionar la morfología de los MUAPs

2

Segmentar MUAPs por umbral adaptativo

3

Extraer features temporales, espectrales y de Wavelet

4

Consolidar deltoides + bíceps en un único dataset

5

Entrenar y comparar Random Forest vs. Red Neuronal (MLP)

6

Evaluar desempeño y relevancia de cada característica

Pipeline secuencial de cinco etapas



Comparación con antecedentes: la segmentación se inspira en Quiroga et al. (spike sorting); el conteo de fases y giros sigue a Willison; los rangos de referencia siguen a Buchthal et al. y a los estándares de la IFCN. A diferencia de estos, este trabajo suma clasificación automática por AA/RN.

Objetivos de mínima y de máxima



De mínima

- Pipeline funcional de extremo a extremo: acondicionamiento, segmentación, extracción de features y clasificación.
- Superar al azar uniforme (33% para 3 clases).
- Superar la predicción constante de la clase mayoritaria (más exigente por el desbalance entre grupos).



De máxima

- Discriminación robusta y estadísticamente significativa entre las tres condiciones.
- Validar con separación por paciente (no por MUAP) entre train/test, evitando data leakage.
- Complementar con pruebas estadísticas de diferencia entre grupos.

Preprocesamiento



Pasa banda IIR Butterworth (4º orden)

20–1000 Hz: acota el ancho de banda útil del MUAP.



Filtro notch en 50 Hz

Elimina el ruido de línea de la red eléctrica.



Filtro óptimo de Wiener

Reduce de forma adaptativa el ruido blanco gaussiano.

De la señal continua a un vector de características

Umbralización adaptativa: se detecta un pico cuando la señal supera 4 veces la desviación estándar del ruido de reposo. Cada MUAP se recorta en una ventana de 30 ms centrada en su pico principal.

4 características clásicas

- Duración total (envolvente de energía, criterio de permanencia 0.8 ms)
- Amplitud pico a pico
- Número de fases (histéresis $1.5 \times \sigma$ ruido)
- Número de giros (histéresis $2 \times \sigma$ ruido, piso 30 μV)

Features ampliadas

- Forma de onda: AUC, ratio amplitud/duración, skewness, kurtosis
- Espectrales: frecuencia media y mediana (FFT)
- Energía relativa en 3 bandas: baja (0–200 Hz), media (200–500 Hz), alta (>500 Hz)
- Dataset final combina deltoides + bíceps braquial

Transformada Wavelet Discreta (DWT)



A diferencia de Fourier, la Wavelet localiza **simultáneamente en qué escala temporal y en qué banda de frecuencia** se concentra la energía del MUAP: ideal para señales transitorias y no estacionarias.

db4

Wavelet madre:
Daubechies de orden 4

4 niveles

de descomposición de
detalle

Energía relativa

por nivel (aproximación +
4 detalles)

Entropía de Shannon

de esa distribución de
energía

Hipótesis de trabajo: los MUAPs polifásicos y desincronizados de miopatías y neuropatías muestran una energía más dispersa (mayor entropía) que los MUAPs sanos, más compactos en el dominio tiempo-frecuencia.

Modelos elegidos

Variables estandarizadas (media 0, desvío 1), PCA previo para visualización, partición 80/20 estratificada por clase



Random Forest

Aprendizaje Automático clásico

- Ensamble de 300 árboles de decisión
- `class_weight = "balanced"`
- Robusto frente a features en distintas escalas
- Permite interpretar la importancia relativa de cada característica



Red Neuronal (MLP)

Perceptrón Multicapa

- Dos capas ocultas: 64 y 32 neuronas
- Activación ReLU, optimizador Adam
- Entrenada por retropropagación del error
- $\alpha (L2) = 1e-3 \cdot \max_iter = 1000$


Características por condición

Característica	Sano	Miopatía	Neuropatía
Amplitud (μV)	1164.8 ± 724.5	1564.4 ± 1069.8	3698.6 ± 2011.4
AUC	2.87 ± 2.58	4.11 ± 3.94	9.12 ± 7.46
Ratio Amp/Dur	115.3 ± 75.2	133.1 ± 87.4	364.4 ± 214.7
Energía banda alta	0.070 ± 0.072	0.086 ± 0.094	0.058 ± 0.072
Entropía Wavelet	0.045 ± 0.044	0.055 ± 0.058	0.038 ± 0.042

Neuropatía: las métricas de energía y tamaño (AUC, Ratio Amp/Dur) triplican los valores sanos lo cual refleja la hipertrofia de la UM por reinervación.

Miopatía: su naturaleza desorganizada se capta mejor con descriptores espectrales y de complejidad (energía de banda alta y entropía Wavelet más altas).

Dispersión PCA de cada clase




Solapamiento masivo entre las tres clases en el centro del espacio latente.

Neuropatía tiende al extremo positivo de PC2.

Miopatía tiende a valores altos de PC1.

No hay separabilidad lineal clara. Esta complejidad geométrica justifica el uso de clasificadores no lineales y de ensamble: Random Forest y MLP.

Matriz de confusión




Clase	Precisión	Sensib.	F1
Sano	0.79	0.91	0.84
Miopatía	0.74	0.46	0.57
Neuropatía	0.89	0.94	0.92

Neuropatía: desempeño más alto (sensibilidad 93.6%, precisión 89.5%), casi sin confundirse con miopatía.

Sano: 1248 registros correctos, sensibilidad 90.5%.

Miopatía: clase más difícil (sensibilidad 46.3%). 310 potenciales miopáticos confundidos con sanos, por su baja amplitud.

Importancia relativa de cada característica




Top 3 features (Ratio Amp/Dur, Amplitud, AUC) concentran hasta el **46% de la importancia total** del modelo.

Segundo escalón: descriptores morfológicos (fases y giros).

Las variables espectrales (bandas de frecuencia, entropía Wavelet) tienen aportes menores: actúan como descriptores complementarios que refinan las fronteras de decisión más finas.

5. RESULTADOS - RED NEURONAL (MLP)

Matriz de confusión



Clase	Precisión	Recall	F1
Sano	0.83	0.83	0.83
Miopatía	0.63	0.63	0.63
Neuropatía	0.93	0.94	0.93

Neuropatía: se mantiene como el mayor éxito (F1 = 0.93), con solo 20 falsos miopáticos y 22 falsos sanos.

Sano: sensibilidad 82.9%, F1 = 0.83.

Miopatía: mejora frente a Random Forest — sensibilidad 62.6% (vs. 46.3%), rescatando un 16.3% más de potenciales miopáticos reales.

Random Forest vs. Red Neuronal (MLP)

Modelo	Precisión	F1-macro
Random Forest	0.80	0.78
MLP	0.81	0.80



El MLP supera globalmente al Random Forest, incrementando el F1-macro de 0.78 a 0.80 y logrando un diagnóstico global más equilibrado entre las tres clases.

Trade-off clínicamente aceptable: el MLP incrementa los falsos positivos miopáticos en sanos (208 vs. 87 en RF), pero desde una perspectiva de screening médico resulta preferible minimizar falsos negativos: los falsos positivos se filtran luego con el juicio del especialista.

Un pipeline completo, con margen de mejora claro



Se logró un pipeline automatizado de extremo a extremo, que supera el azar uniforme (33.3%) y la predicción por clase mayoritaria. La Transformada Wavelet y las métricas espectrales elevaron la capacidad predictiva: el MLP alcanzó una precisión ponderada de 0.81 y F1-macro de 0.80, con neuropatías discriminadas con $F1 = 0.93$.

Limitaciones

- Etiquetado a nivel de paciente, no de MUAP individual.
- Partición train/test por MUAP (no por paciente): riesgo de data leakage.
- Alta dispersión (SD) en varias métricas limita la contundencia estadística de las diferencias entre grupos.

Trabajo a futuro

- Repetir el entrenamiento con partición por paciente.
- Incorporar pruebas estadísticas formales (ANOVA / no paramétricas).
- Explorar una CNN 1D directamente sobre la forma de onda cruda.
- Buscar un dataset con etiquetado a nivel de MUAP individual.

Muchas gracias

Grupo 10 - Suarez - Kestelboim - Caroccia